

# Análisis Convexo: Subdiferenciales

PROYECTO FINAL

Roberto Vásquez Martínez

UNIVERSIDAD DE GUANAJUATO  
Departamento de Matemáticas



Profesor: Dr. Joaquín Peña Acevedo

10 de junio de 2022

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales

# Contenidos

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Motivación

- Curso de Optimización: Métodos en los cuales se utiliza la derivada y segundas derivadas.
- $f : \mathbb{R}^n \rightarrow \mathbb{R}$  es la función objetivo y no es diferenciable no podemos utilizar ninguno de estos métodos.



# Convexidad

Un caso importante es considerar  $f$  una función convexa, donde vimos condiciones necesarias y suficientes para el punto óptimo de  $f$  cuando esta función es diferenciable.

Relajando esta condición, analizaremos el caso cuando  $f$  es convexa pero no diferenciable.



# Convexidad

Un caso importante es considerar  $f$  una función convexa, donde vimos condiciones necesarias y suficientes para el punto óptimo de  $f$  cuando esta función es diferenciable.

Relajando esta condición, analizaremos el caso cuando  $f$  es convexa pero no diferenciable.



# Esquema

- 1 Obtener condiciones de optimalidad para funciones convexas no diferenciables.
- 2 Generalizar la noción de aproximación lineal y derivada direccional.
- 3 Construir generalizaciones del método de descenso y ejemplificar el uso de subdiferenciales en la optimización convexa.



# Esquema

- 1 Obtener condiciones de optimalidad para funciones convexas no diferenciables.
- 2 Generalizar la noción de aproximación lineal y derivada direccional.
- 3 Construir generalizaciones del método de descenso y ejemplificar el uso de subdiferenciales en la optimización convexa.





# Esquema

- 1 Obtener condiciones de optimalidad para funciones convexas no diferenciables.
- 2 Generalizar la noción de aproximación lineal y derivada direccional.
- 3 Construir generalizaciones del método de descenso y ejemplificar el uso de subdiferenciales en la optimización convexa.



# Contenidos

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



Para obtener métodos de optimización como los de búsqueda en línea es fundamental la idea de *aproximación lineal*. El tipo de funciones que aproximarán a las funciones convexas serán **sublineales**, en ese sentido tendremos *aproximación sublineal*.



Para obtener métodos de optimización como los de búsqueda en línea es fundamental la idea de *aproximación lineal*. El tipo de funciones que aproximarán a las funciones convexas serán **sublineales**, en ese sentido tendremos *aproximación sublineal*.



# Funciones sublineales #1

## Definición (Sublinealidad)

Una función  $\sigma : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  se dice **sublineal** si se cumple

$$\sigma(t_1 x_1 + t_2 x_2) \leq t_1 \sigma(x_1) + t_2 \sigma(x_2) \quad \forall (x_1, x_2) \in \mathbb{R}^n \times \mathbb{R}^n.$$

$$\text{y } (t_1, t_2) \in \mathbb{R}^+ \times \mathbb{R}^+$$



## Funciones sublineales #2

Observamos que el conjunto de funciones sublineales es un subconjunto de la clase de funciones convexas.



# Contenidos

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Intuición

- Sabemos que forma tienen los funcionales lineales de espacio de Hilbert.
- Las aproximaciones lineales de funciones objetivo  $f$  diferenciables son de esta forma.
- El resultado teórico que nos caracteriza a estos funcionales lineales es el *Teorema de Representación de Riesz*.





# Motivación

Quisieramos un teorema similar para el caso de funciones pues

- 1 Brinda intención geométrica.
- 2 Conocer la forma de estas funciones sublineales es útil en el esquema de optimización.



# Funciones sublineales cerradas #1

Sin embargo, no podemos considerar la clase de todas las funciones sublineales. Nos restringimos a la clase de funciones **sublineales cerradas**.



## Funciones sublineales cerradas #2

### Definición (Epígrafe)

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  no idénticamente  $+\infty$ . La epígrafe de  $f$  la definimos como el conjunto

$$\text{epi } f = \{(x, r) \in \mathbb{R}^n \times \mathbb{R} : r \geq f(x)\}.$$

### Definición (Función cerrada)

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  no idénticamente  $+\infty$ . Decimos que  $f$  es cerrada si  $\text{epi } f$  es un conjunto cerrado en la topología producto.



## Funciones sublineales cerradas #2

### Definición (Epígrafe)

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  no idénticamente  $+\infty$ . La epígrafe de  $f$  la definimos como el conjunto

$$\text{epi } f = \{(x, r) \in \mathbb{R}^n \times \mathbb{R} : r \geq f(x)\}.$$

### Definición (Función cerrada)

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  no idénticamente  $+\infty$ . Decimos que  $f$  es cerrada si  $\text{epi } f$  es un conjunto cerrado en la topología producto.



# Función Soporte

El tipo de representación que necesitamos se vale del siguiente concepto.

## Definición (Función Soporte)

Sea  $S \subset \mathbb{R}^n$  no vacío y la función  $\sigma_S : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  definida como

$$\sigma_S(x) = \sup\{\langle s, x \rangle : s \in S\}.$$

Decimos que  $\sigma_S$  es la función soporte del conjunto  $S$ .



# Representación

## Teorema de Representación

Sea  $\sigma : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  función sublineal cerrada y

$$S_\sigma = \{s \in \mathbb{R}^n : \langle s, d \rangle \leq \sigma(d) \quad \forall d \in \mathbb{R}^n\}.$$

Entonces  $\sigma$  es la función soporte de  $S_\sigma$ .

Así, la representación de funciones sublineales cerradas se reduce al supremo de funcionales lineales que la minorizan.



# Contenidos

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Preliminares

Al igual que en el caso diferenciable, tenemos la noción de *derivada direccional*, que de manera similar nos permitirá generalizar la aproximación que tenemos en el sentido del Teorema de Taylor y así construir métodos de descenso para este caso.

En primer lugar, dado  $x, d \in \mathbb{R}^n$

$$q(t) = \frac{f(x + td) - f(x)}{t} \quad \text{para } t > 0. \quad (1)$$





### Definición (Derivada Direccional)

Sean  $x, d \in \mathbb{R}^n$  y  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  función convexa. Entonces la derivada direccional de  $f$  en  $x$  en la dirección  $d$  es

$$f'(x, d) := \lim_{t \downarrow 0} q(t) = \inf\{q(t) : t > 0\}.$$

Se puede probar que la derivada direccional es una función sublineal cerrada.



# Contenidos

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Subdiferencial I

## Definición (Subdiferencial I)

El *subdiferencial*  $\partial f(x)$  de  $f$  en  $x$  es el conjunto no vacío del cual  $f'(x, \cdot)$  es función soporte, i.e.

$$\partial f(x) = \{s \in \mathbb{R}^n : \langle s, d \rangle \leq f'(x, d) \quad \forall d \in \mathbb{R}^n\}.$$

Un vector  $s \in \partial f(x)$  decimos que es un *subgradiente* de  $f$  en  $x$ .



# Subdiferencial II

Esta definición carece de facilidad de cómputo. Mostramos una equivalencia.

## Definición (Subdiferencial II)

El subdiferencial  $\partial f(x)$  es el conjunto de vectores  $s$  que satisfacen

$$f(y) \geq f(x) + \langle s, y - x \rangle \quad \forall y \in \mathbb{R}^n.$$



# Contenidos

Enero-Junio 2022

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Condiciones de primer orden

A partir de las definiciones anteriores es fácil demostrar lo siguiente

## Teorema (Condiciones de optimalidad)

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  convexa. Las siguientes condiciones son equivalentes

- 1  $f$  es minimizada en  $x_*$  sobre  $\mathbb{R}^n$ .
- 2  $0 \in \partial f(x_*)$ .
- 3  $f'(x_*, d) \geq 0$  para toda  $d \in \mathbb{R}^n$ .



# Contenidos

Enero-Junio 2022

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Descenso Máximo

En el sentido del Teorema anterior podemos buscar la definición de máximo descenso. La dirección de descenso máximo se conceptualiza de la siguiente forma

## Definición (Dirección de Máximo Descenso)

Sea  $\|\cdot\|$  una norma en  $\mathbb{R}^n$ . Una dirección de máximo descenso normalizada de  $f$  en  $x$ , con respecto a la norma  $\|\cdot\|$ , es una solución al problema de optimización

$$\text{mín}\{f'(x, d) : \|d\| = 1\}, \quad (2)$$

o de forma equivalente, podemos escribir en notación min-máx este problema de optimización ya que  $f'(x, \cdot)$  es función soporte de  $\partial f(x)$

$$\text{mín}_{\|d\|=1} \max_{s \in \partial f(x)} \langle s, d \rangle,$$

y ese máximo se alcanza gracias a que  $\partial f(x)$  es un compacto.



# Contenidos

Enero-Junio 2022

- 1 Introducción
  - Motivación e Intuición
- 2 Sublinealidad
  - Definiciones y Resultados Importante
  - Teorema de Representación
- 3 Subdiferencial
  - Derivada Direccional
  - Definición Formal
  - Condiciones de optimalidad
- 4 Método de Descenso
  - Dirección de Descenso
  - Algoritmo de Descenso con Subdiferenciales



# Algoritmo de Descenso Máximo

## Algoritmo de Descenso Máximo

Empezamos con  $x_1 \in \mathbb{R}^n$ . Ajustamos  $k = 1$ . Repetimos los siguientes pasos:

- ❶ **(Criterio de Paro)**  $0 \in \partial f(x_k)$
- ❷ **(Dirección de Descenso)** Para la norma  $\|\cdot\|$  en  $\mathbb{R}^n$ . Hallar  $d_k$  solución de (2)
- ❸ **(Búsqueda en línea)** Encontrar  $t_k > 0$  de forma que  $x_{k+1} := x_k + t_k d_k$  es tal que

$$f(x_{k+1}) < f(x_k)$$

- ❹ Hacer  $k = k + 1$  y volver a (i).



# Referencias



R. Tibshirani et al.  
*Statistical Learning with Sparsity.*  
Taylor & Francis Group, 2015.



J. Nocedal, S. Wright  
*Numerical Optimization.*  
Springer, 2006.



J. Hiriart-Urruty.  
*Convex Analysis and Minimization Algorithms I: Fundamentals.*  
Springer, 1993.



R. Tibshirani.  
*Regression Shrinkage and Selection via the LASSO.*  
*Journal of the Royal Statistical Society.* 58(1), 1996.

